

KIMI 模型家族与演进全景

从 K1 到 K3：版本差异 × 架构变化 × 应用价值

核对日期 2026-09-19 | 一张图阅读顺序：上方看演进，中间查版本，下方选应用

16 个公开权重

8 个主线版本 + 8 个支线版本

18 个历史名称条目

另列 K1、K1.5；不等于 18 套架构

19 个官方仓库

含 Moonlight ×2、MoonViT ×1

01 演进逻辑：训练能力 → 多模态 → 架构重构

箭头表示发布 / 技术演进，不表示每个模型都由前一个版本的权重直接训练而来。



02 主线逐项对照：10 个名称，其中 8 个公开权重版本

版本	变化在哪里	应用价值 / 边界
K1	早期历史版本；完整结构资料尚未核验	作为历史节点；不推测层数、参数或精度
K1.5	强化学习、长思考、长转短；多模态推理	数学、代码、视觉推理；未公开同等权重细节
K2-Base	基础权重；61 层 MLA + MoE；128K	继续训练、领域适配；非成品聊天助手
K2-Instruct	同主干；强化指令遵循与工具使用	文本助手、代码、工具调用
K2-Instruct-0905	主干延续；128K → 256K；代码改进	长文档、更多代码上下文、前端开发
K2-Thinking	强化多步思考与工具使用；路由专家 INT4	复杂推理、研究；可能需要更多思考时间
K2.5	延续语言主干，加入视觉塔和多模态训练	图片 / 视频理解、截图转代码
K2.6	主干尺寸延续；长流程代码和智能体增强	多文件工程、持续工具调用与执行
K2.7-Code	主干尺寸延续；代码专项与思考效率优化	软件开发、调试；非所有任务都必然更强
K3	93 层混合注意力 + LatentMoE + AttnRes；1M	大代码库、多模态研究、长流程复杂工程

03 结构与部署：K3 的优势来自哪里

K2 主干：约 1T 级

61 层全局 MLA；隐藏宽度 7168
384 个路由专家，每 token 选 8；另有 1 共享
单个路由专家约 4404 万参数
早期 FP8；Thinking / 2.5–2.7 路由专家 INT4

K3：约 2.8T 级

93 层 = 69 KDA + 24 全局 MLA；宽度 7168
896 选 16；2 共享；路由空间压至 3584
单个路由专家约 3303 万参数；加入 AttnRes
路由专家 MXFP4，量化感知训练

实际收益与代价

混合注意力：降低长序列缓存增长压力
潜在空间专家：扩大容量、控制单专家尺寸
跨层读取：有选择地利用较早层的信息
更大容量 ≠ 比 K2 更便宜或更快

04 平行支线：8 个公开版本，不是 K2 的八种大小

视觉 VL · 3 个版本

Instruct：图像、文档、截图理解
Thinking：增加多步视觉推理
Thinking-2506：视觉 / 视频与推理效率更新
用途：图表、视觉题、高分辨率图片

音频 Audio · 2 个版本

7B：基础版本，供研究与继续训练
7B-Instruct：指令与音频交互
用途：转写、音频理解、语音交互
名称中的 7B 不等于全系统参数量

代码 Dev · 1 个版本

Dev-72B：软件工程专项模型
基于 Qwen2.5-72B，并非缩小的 K2
用途：仓库问题修复、生成补丁、测试反馈

长文本 Linear · 2 个版本

48B-A3B-Base：混合注意力基础版本
48B-A3B-Instruct：长文本指令版本
用途：高效长文本部署；KDA 技术通向 K3
A3B 是激活参数，存储仍需完整专家权重

阅读边界：量化不是所有层统一低精度；上下文上限不等于可靠召回率；应用定位不是统一条件下的性能排名。

来源：Moonshot AI 官方模型目录、各版模型卡 / 配置 / 权重文件头；K1.5 论文、K3 技术报告。K1 原始结构未核验。

huggingface.co/moonshotai/models · arxiv.org/abs/2501.12599 · github.com/MoonshotAI/Kimi-K3